Ejercicio 7. El esquema del proyecto asignado

El archivo de definición de datos tomado del repositorio del proyecto asignado (`sql/00-datawarehouse_tables.sql`) define el esquema en estrella implementado sobre el gestor relacional PostgreSQL:

```
CREATE TABLE IF NOT EXISTS dim_economia ( id_economia INT PRIMARY KEY, nombre_entidad VARCHAR(100),

entidad DOUBLE PRECISION, produccion_bruta_total DOUBLE PRECISION, insumos_utilizados DOUBLE PRECISION,

consumo_intermedio DOUBLE PRECISION, valor_agregado DOUBLE PRECISION, formacion_capital DOUBLE PRECISION,

activos_fijos_adquiridos DOUBLE PRECISION ); CREATE TABLE IF NOT EXISTS dim_sismos ( id_sismo INT PRIMARY KEY,

magnitud DOUBLE PRECISION, latitud DOUBLE PRECISION, longitud DOUBLE PRECISION, profundidad DOUBLE

PRECISION, referencia_de_localizacion VARCHAR(100), estado VARCHAR(100), nombre_estado VARCHAR(100) );

CREATE TABLE IF NOT EXISTS dim_tiempo ( id_tiempo INT PRIMARY KEY, hora_utc TIME, fecha DATE, anio INT, mes

INT, dia INT, trimestre INT ); CREATE TABLE IF NOT EXISTS dim_zonas ( id_zonas INT PRIMARY KEY, entidad INT,

nom_ent VARCHAR(100), pobtot BIGINT, pobfem BIGINT, pobmas BIGINT ); CREATE TABLE

fact_impacto_sismos_imputed ( id_sismo INT, id_zonas INT, id_economia INT, id_tiempo INT, poblacion_afectada BIGINT,

impacto_economico DOUBLE PRECISION, determinante_de_riesgo DOUBLE PRECISION, riesgo_proporcional DOUBLE

PRECISION, indice_zscore DOUBLE PRECISION, FOREIGN KEY (id_sismo) REFERENCES dim_sismos(id_sismo), FOREIGN

KEY (id_zonas) REFERENCES dim_zonas(id_zonas), FOREIGN KEY (id_economia) REFERENCES

dim_economia(id_economia), FOREIGN KEY (id_tiempo) REFERENCES dim_tiempo(id_tiempo) );
```

7.1 Las reglas detrás del esquema (Explicación tabla por tabla)

1. Tabla `dim_sismos`

- **Regla que explica su origen: Regla de Entidades Fuertes o Regulares (Regla 1)**. En el modelo conceptual EER, el sismo constituye una entidad fuerte e independiente con existencia propia en el

dominio. Se transforma en una tabla relacional directa que incorpora como columnas todos sus atributos atómicos (magnitud, latitud, longitud, profundidad, referencia).

- **Clave Primaria (PK):** `id_sismo` (INT PRIMARY KEY).
- **Claves Foráneas (FK):** Ninguna declarada.
- **Restricciones declaradas:** Restricción de unicidad y no nulidad implícitas en la clave primaria.

2. Tabla `dim_zonas`

- **Regla que explica su origen: Regla de Entidades Fuertes o Regulares (Regla 1)**. Modela la entidad territorial y demográfica de las demarcaciones estatales del país con sus atributos de censo poblacional (pobtot, pobfem, pobmas).
- **Clave Primaria (PK):** `id_zonas` (INT PRIMARY KEY).
- **Claves Foráneas (FK):** Ninguna declarada.
- **Restricciones declaradas:** Restricción de clave primaria sobre `id_zonas`.

3. Tabla `dim_tiempo`

- **Regla que explica su origen:** En el modelo conceptual EER corresponde a un **atributo compuesto** o entidad débil cronológica ligada a la ocurrencia del sismo. En el esquema dimensional se materializa bajo la **Regla de Entidad Regular con clave subrogada**, desagregando las componentes temporales en jerarquías analíticas fijas (año, mes, día, trimestre).
- **Clave Primaria (PK):** `id_tiempo` (INT PRIMARY KEY).
- **Claves Foráneas (FK):** Ninguna declarada en el DDL.
- **Restricciones declaradas:** Restricción de clave primaria sobre `id_tiempo`.

4. Tabla `dim_economia`

- **Regla que explica su origen:** En el modelo conceptual EER original era una **Entidad Débil** dependiente de la entidad territorial `ZONA` (la economía no existe en el vacío, sino condicionada al ámbito geográfico y al periodo censal). Sin embargo, en el esquema dimensional se transformó creando una **clave subrogada artificial** (`id_economia`), absorbiendo atributos propios de la zona.
- **Clave Primaria (PK):** `id_economia` (INT PRIMARY KEY).
- **Claves Foráneas (FK):** Ninguna declarada en el DDL (no tiene FK referenciando a `dim_zonas`).
- **Restricciones declaradas:** Restricción de clave primaria sobre `id_economia`.

5. Tabla `fact_impacto_sismos_imputed`

- **Regla que explica su origen: Regla de Relación Muchos a Muchos (M:N) o Relación n-aria con atributos descriptivos (Regla 5)**. En el EER modela la asociación multidimensional entre el

evento sísmico, la demarcación afectada, su contexto económico y la ventana temporal, almacenando las medidas métricas del impacto.

- **Clave Primaria (PK): No tiene clave primaria declarada en el DDL**. Conceptual y lógicamente su clave candidata compuesta está formada por `(id_sismo, id_zonas, id_economia, id_tiempo)`.
- **Claves Foráneas (FK):**
  - `FOREIGN KEY (id_sismo) REFERENCES dim_sismos(id_sismo)`
  - `FOREIGN KEY (id_zonas) REFERENCES dim_zonas(id_zonas)`
  - `FOREIGN KEY (id_economia) REFERENCES dim_economia(id_economia)`
  - `FOREIGN KEY (id_tiempo) REFERENCES dim_tiempo(id_tiempo)`
- **Restricciones declaradas:** Cuatro restricciones de integridad referencial (FOREIGN KEY).

7.2 Dónde se aparta de las reglas (Desnormalización dimensional)

Un almacén dimensional desnormaliza intencionalmente para privilegiar el desempeño en lecturas masivas OLAP sobre la pureza de la normalización. Se destacan cuatro decisiones:

1. **Atributos de otra entidad embebidos en dimensiones (Transgresión de la 3FN):** En `dim_economia` se almacenan `nombre_entidad` y `entidad`; en `dim_sismos` se repiten `estado` y `nombre_estado`. En una transformación relacional estricta (3FN), el nombre y código de estado pertenecen exclusivamente a `ZONA`.
   Qué se gana: Elimina la necesidad de realizar operaciones de JOIN con tablas geográficas en consultas de filtrado analítico frecuente, acelerando las respuestas del dashboard.
   Qué se pierde: Se introduce redundancia física y riesgo de inconsistencia (anomalías de actualización si cambia el nombre oficial de una entidad).
2. **Almacenamiento físico de atributos derivados:** En `dim_tiempo` se almacenan físicamente `anio`, `mes`, `dia` y `trimestre` (obtenibles mediante funciones de fecha). En `fact_impacto_sismos_imputed` se guardan métricas computadas (`determinante_de_riesgo`, `riesgo_proporcional`, `indice_zscore`).
   Qué se gana: Tiempos de respuesta inmediatos en agregaciones analíticas (`GROUP BY anio, trimestre`) sobre cientos de miles de registros sin recargar la CPU del servidor recalculando fórmulas.
   Qué se pierde: Mayor consumo de disco y alto acoplamiento: si la formulación del índice de riesgo cambia, los registros históricos requieren una costosa actualización por lotes (batch update).
3. **Uso generalizado de Claves Subrogadas sintéticas:** En lugar de claves naturales compuestas del dominio (ej. clave INEGI para estados, coordenadas + timestamp para sismos), se imponen identificadores enteros artificiales (`INT PRIMARY KEY`).

Qué se gana: Índices B-Tree altamente compactos y claves foráneas de 4 bytes en la tabla de hechos con millones de filas, maximizando el uso de la memoria RAM del gestor.
Qué se pierde: Pérdida de semántica directa en la clave y sobrecarga de procesamiento en la capa ETL para mapear y generar las llaves sustitutas.

4. **Ausencia de Clave Primaria declarada en la Tabla de Hechos:** La tabla central `fact_impacto_sismos_imputed` omite la definición de una PK.
Qué se gana: Carga ultrarrápida de datos masivos (`COPY / BULK INSERT`) al eludir la verificación de unicidad fila por fila.
Qué se pierde: El motor no garantiza a nivel relacional la ausencia de tuplas duplicadas para una misma combinación dimensional.

7.3 Comparación entre modelos (EER vs. Relacional)

Concepto EER	Transformación al Modelo Relacional	Qué se ganó (Relacional)	Qué se perdió (Relacional)	Ejemplo en Proyecto Propio (UIF)	Ejemplo en Proyecto Asignado (Sismos)
Entidades Fuertes	Tabla independiente con clave primaria `PRIMARY KEY`.	Simplicidad estructural, almacenamiento en bloques y soporte para índices de alta velocidad.	Pérdida de la semántica gráfica de interrelaciones directas de dominio.	`CONTRIBUYENTE`, `CUENTA_BANCARIA`.	`dim_sismos`, `dim_zonas`.
Entidades Débiles	Tabla cuya PK incluye la FK de la entidad padre, o clave subrogada con FK no nula.	Integridad referencial declarativa y políticas de borrado en cascada (`ON DELETE CASCADE`).	La dependencia de existencia conceptual queda reducida a restricciones sintácticas de nulidad y FK.	`DETALLE_DESGLOSE` (débil de `REPORTE`), `EXPEDIENTE` (de `ALERTA`).	`dim_economia` (dependiente d `ZONA` en EE independizada e DW).
Relaciones M:N	Tabla intermedia puente con las FKs de las entidades participantes formando la PK	Estructura normalizada para almacenar atributos propios de la relación sin	Obligatoriedad de múltiples uniones (`JOIN`), penalizando el rendimiento en	Relación entre transacciones bancarias sospechosas y causales normativas	`fact_impacto_sismos_imputed` relacionand sismos, zona economía

Concepto EER	Transformación al Modelo Relacional	Qué se ganó (Relacional)	Qué se perdió (Relacional)	Ejemplo en Proyecto Propio (UIF)	Ejemplo en Proyecto Asignado (Sismos)
	compuesta.	redundancia de cabecera.	consultas masivas.	de alerta.	tiempo.
Jerarquías (Especialización)	Estrategias: tablas separadas por subclase, solo subclases con campos heredados, o tabla única aplanada.	Flexibilidad de ingeniería: optimizar para lecturas rápidas (aplanando) o para integridad estricta.	El estándar SQL no valida nativamente restricciones de disyunción o cobertura total sin triggers.	`CONTRIBUYENTE` jerarquizado en `PERSONA_FÍSICA` y `PERSONA_MORAL` ({d, t}).	En sismos aplanaron tip de eventos zonas territoriales dimensiones únicas.
Atributos Multivaluados	Tabla auxiliar separada con el valor y FK al padre (o tipos modernos `ARRAY / JSONB`).	Cumplimiento de la 1FN (atomicidad) y capacidad de indexar individualmente cada valor.	Proliferación de tablas y sobrecarga en operaciones sencillas de recuperación de perfil.	Múltiples teléfonos o correos electrónicos de un contribuyente investigado.	En el DW desglosaron columnas atómicas individuales (`pobfem`, `pobmas` `dim_zonas`).

Ejercicio 8. Cambio de esquema

8.1 Tablas, columnas y restricciones nuevas

Para implementar la actualización automática de datos desde el Servicio Sismológico Nacional (SSN) e incorporar el subsistema de Aprendizaje Automático para la detección en tiempo real de anomalías y riesgo, se integraron dos tablas:

1. Tabla `control_ingesta_automatica` (Auditoría del Pipeline SSN)

- `id_lote SERIAL PRIMARY KEY`: Identificador secuencial de cada corrida de sincronización programada.
- `fecha_inicio_ingesta TIMESTAMP WITH TIME ZONE DEFAULT`